

UNIVERSIDAD TECNOLÓGICA DE PANAMÁ



**FACULTAD DE INGENIERÍA DE
SISTEMAS COMPUTACIONALES**

**CARRERA LICENCIATURA EN INGENIERÍA DE SISTEMAS Y
COMPUTACIÓN**

Análisis de Datos y Toma de Decisiones

**Tarea # 3: Dashboards en Python – Calidad de Aire con el dataset Air
Quality UCI**

Profesor: Sánchez Galan, Javier

Estudiantes: Villar, Nathanael; 8-975-750

Medrano, Danna; 20-14-7715

Archibold, Elizabeth; 3-757-871

SEMESTRE I

6 de julio de 2026

Introducción del Informe

La tarea no 3 consiste en la elaboración de un Dashboard interactivo usando el lenguaje Python. Se debe manejar archivos de base de datos basándose en los repositorios proveídos por el profesor y manipular los datos usando diversos módulos, como lo son scikit-learn o numpy, usando la analítica de datos y el manejo apropiado de valores faltantes con métodos de imputación. Posterior a eso, se deberá visualizar dichos datos con la ayuda de gráficas usando Matplotlib y diseñando una interfaz apropiada con Flask y Dash, incluyendo controladores que responden a entradas del usuario.

El siguiente informe tiene el propósito de documentar el trabajo elaborado por el grupo – el dataset elegido junto con el desglose de variables de este, tratamiento de datos escogido y una tabla comparativa de valores faltantes, detalles del análisis exploratorio de datos (EDA), entrenamiento del modelo de machine learning (ML), visualizaciones de diversas gráficas del Dashboard, y resultados de la ejecución de la integración.

Tabla de Contenido

1. Introducción al conjunto de datos.....	3
1.1 Variables del dataset.....	3
2. Tratamiento de datos realizado.....	4
2.1 Resumen de valores faltantes (antes de imputar).....	4
3. Metodología de análisis.....	4
3.1 Análisis Exploratorio de Datos (EDA).....	4
3.2 Modelo de Machine Learning.....	5
4. Visualizaciones del Dashboard.....	5
4.1 Serie de tiempo.....	6
4.2 Distribución y normalidad.....	6
4.3 Estacionalidad mensual.....	7
4.4 Correlación entre variables.....	7
4.5 Calidad de los datos.....	8
4.6 Controladores (callbacks).....	8
5. Resultados de la ejecución de la integración.....	8
Referencias.....	9

1. Introducción al conjunto de datos

El proyecto utiliza el dataset Air Quality del UCI Machine Learning Repository (De Vito, S., 2008; DOI: 10.24432/C59K5F), disponible en <https://archive.ics.uci.edu/dataset/360/air+quality>. El conjunto de datos contiene 9357 lecturas horarias recolectadas entre el 10 de marzo de 2004 y el 4 de abril de 2005 por un dispositivo multisensor de óxidos metálicos instalado a nivel de calle en una zona significativamente contaminada de una ciudad italiana.

El dispositivo incluye cinco sensores químicos de bajo costo (CO, NMHC, NOx, NO2 y O3) cuyas respuestas se contrastan contra concentraciones de referencia certificadas, medidas por un analizador de referencia co-ubicado. Esto convierte al dataset en un caso clásico de calibración de sensores de bajo costo (problema de regresión supervisada) y, a la vez, en una serie de tiempo multivariada apta para análisis de distribución, estacionalidad y correlación.

1.1 Variables del dataset

Variable	Descripción	Unidad
CO(GT)	Concentración media horaria real de CO (analizador de referencia)	mg/m ³
PT08.S1(CO)	Respuesta del sensor promediada por hora (nominalmente dirigida a CO)	—
NMHC(GT)	Concentración promedio horaria real de hidrocarburos no metánicos (analizador de referencia)	µg/m ³
C6H6(GT)	Concentración verdadera de benceno promedio por hora (analizador de referencia)	µg/m ³
PT08.S2(NMHC)	Respuesta del sensor promediada por hora (nominalmente dirigida a NMHC)	—
NOx(GT)	Concentración verdadera de NOx promedio por hora (analizador de referencia)	ppb
PT08.S3(NOx)	Respuesta del sensor promediada por hora (nominalmente dirigida a NOx)	—
NO2(GT)	Concentración real de NO2 promediada por hora (analizador de referencia)	µg/m ³
PT08.S4(NO2)	Respuesta del sensor promediada por hora (nominalmente dirigida a NO2)	—
PT08.S5(O3)	Respuesta del sensor promediada por hora (principalmente para O3)	—
T	Temperatura	°C
RH	Humedad relativa	%
AH	Humedad absoluta	—

2. Tratamiento de datos realizado

El CSV original utiliza punto y coma como separador y coma como separador decimal.

El backend de Python (módulo `data_processing.py`) realiza los siguientes pasos:

- Eliminación de columnas y filas completamente vacías, original del CSV
- Construcción de una marca de tiempo (timestamp) combinando las columnas Date y Time, e indexación cronológica del dataset.
- Conversión del código de dato faltante documentado por UCI, el valor -200, a NaN en las 13 columnas numéricas.
- La variable NMHC(GT) se documenta aparte (90.2% de datos faltantes) y se excluye de la imputación masiva para no introducir sesgo artificial.
- Imputación por interpolación temporal lineal para las variables apropiadas
- Generación de variables de calendario (mes, hora, día de la semana) para habilitar el análisis en el dashboard.

2.1 Resumen de valores faltantes (antes de imputar)

Variable	% faltante
NMHC(GT)	90.23
CO(GT)	17.99
NO2(GT)	17.55
NOx(GT)	17.52
PT08.S1(CO)	3.91
PT08.S2(NMHC)	3.91
C6H6(GT)	3.91
PT08.S3(NOx)	3.91
PT08.S4(NO2)	3.91
PT08.S5(O3)	3.91
T	3.91
RH	3.91

3. Metodología de análisis

3.1 Análisis Exploratorio de Datos (EDA)

El EDA (módulo `eda_analysis.py`) siguió los siguientes pasos:

- Estadística descriptiva (media, mediana, desviación estándar, mínimo/máximo, cuartiles) de las 13 variables numéricas.

- Análisis de distribución mediante histogramas con curva normal teórica de referencia superpuesta y cálculo de asimetría (skewness), para contrastar visualmente la forma de cada variable contra una distribución normal.
- Análisis de correlación entre las 13 variables, para identificar relaciones entre sensores de bajo costo y sus valores de referencia, así como entre contaminantes.
- Segmentación temporal (por mes, por hora del día) para detectar patrones
- Detección de outliers mediante diagramas de caja (boxplot) por mes.

3.2 Modelo de Machine Learning

Se entrenó un modelo supervisado de regresión cuyo objetivo es predecir la concentración real de CO (CO(GT)) a partir de las respuestas de los cinco sensores de bajo costo y las variables ambientales (T, RH, AH)

Se compararon dos algoritmos:

- Regresión Lineal
- Random Forest Regressor (200 árboles).

Los datos se dividieron 75/25 (entrenamiento/prueba) y las variables se estandarizaron antes de entrenar.

Resultados sobre el conjunto de prueba:

Modelo	R ²	MAE (mg/m ³)
Regresión Lineal	0.711	0.492
Random Forest	0.800	0.409

El Random Forest captura mejor las relaciones no lineales y las interacciones entre sensores, confirmando que la respuesta conjunta de los cinco sensores permite estimar razonablemente bien la concentración real de CO sin necesidad de un analizador certificado costoso.

4. Visualizaciones del Dashboard

El frontend se implementó utilizando Flask, Dash y Plotly (`app.py`). El dashboard sigue una metodología de "overview + detalle", donde los controles globales (selección de variable, rango de fechas y nivel de agregación temporal) se encuentran en la parte superior. Las selecciones realizadas por el usuario actualizan dinámicamente las gráficas, indicadores y demás elementos visuales ubicados en la parte inferior del panel.

4.1 Serie de tiempo




Figura 1. Serie de tiempo (agregación diaria) del CO de referencia.

Reacciona al dropdown de variable, al selector de fechas y al control de agregación (horaria/diaria/semanal).

4.2 Distribución y normalidad




Figura 2. Histograma de densidad de CO(GT) con la curva normal teórica superpuesta, evidenciando la asimetría positiva de la distribución.

4.3 Estacionalidad mensual




Figura 3. Diagrama de caja mensual de CO(GT), útil para identificar outliers y diferencias por periodo de tiempo en la calidad del aire.

4.4 Correlación entre variables




Figura 4. Matriz de correlación entre las 13 variables numéricas del dataset.

4.5 Calidad de los datos




Figura 5. Porcentaje de valores faltantes (código -200) por variable, antes de la imputación.

4.6 Controladores (callbacks)

El dashboard implementa tres controles interactivos:

- Dropdown de variable de análisis, el cual actualiza lo siguiente dependiendo del compuesto químico escogido:
 - KPIs (Key Performance Indicators)
 - Serie de tiempo
 - Histograma
 - Boxplot mensual
- Selector de rango de fechas (DatePickerRange), el cual filtra todas las gráficas reactivas al período seleccionado.
- Selector de agregación temporal (horaria / diaria / semanal), el cual cambia el remuestreo de la serie de tiempo. Por lo tanto, permite ver la serie de tiempo con más o menos detalle, promediando los datos por hora, día o semana.

5. Resultados de la ejecución de la integración

La integración Backend (limpieza de datos, EDA, modelo de ML) – Frontend (Dash) se ejecutó exitosamente de forma local:

data_processing.py, permitió transformar el archivo CSV original en un conjunto de datos consistente para el análisis. Durante este proceso se eliminaron las columnas y filas vacías generadas por el formato del archivo, se construyó una marca temporal unificando las columnas de fecha y hora, se reemplazó el código de datos faltantes (-200) por valores nulos y se realizó la imputación de los datos faltantes mediante interpolación temporal. Como resultado, se obtuvo un conjunto de datos limpio con 9357 observaciones listo para el análisis exploratorio y el entrenamiento de modelos.

eda_analysis.py, realizó automáticamente el análisis exploratorio del conjunto de datos, generando estadísticas descriptivas, matrices de correlación y análisis de la distribución de las variables. Además, entrenó y evaluó los modelos de Regresión Lineal y Random Forest para estimar la concentración real de CO a partir de las respuestas de los sensores, permitiendo comparar el desempeño de ambos algoritmos mediante métricas como R^2 y MAE.

app.py, integró todos los componentes desarrollados en una aplicación web interactiva utilizando Flask y Dash en <http://127.0.0.1:8050>. El servidor permitió visualizar en tiempo real los resultados del análisis mediante gráficos dinámicos, indicadores KPI y controles interactivos, facilitando la exploración de los datos sin necesidad de ejecutar nuevamente el procesamiento.

Durante las pruebas funcionales se comprobó que cada callback respondiera correctamente a las interacciones del usuario. Los cambios en la variable seleccionada, el rango de fechas y el nivel de agregación temporal actualizaron automáticamente las gráficas, los indicadores y las métricas del dashboard, garantizando una experiencia de exploración consistente y sin errores de sincronización entre el backend y la interfaz.

Como hallazgo principal del análisis: las variables de referencia (CO, NMHC, Benceno, NOx) están altamente correlacionadas entre sí ($r > 0.79$ en la mayoría de los pares), lo cual es consistente con que todas provienen de fuentes de combustión vehicular. El sensor PT08.S3(NOx) está inversamente correlacionado con casi todos los demás ($r \approx -0.6$ a -0.8).

El modelo Random Forest alcanzó un R^2 de 0.80 al estimar la concentración real de CO a partir de las lecturas de los sensores PT08, lo que indica que estos sensores pueden calibrarse para obtener estimaciones confiables de la concentración de CO.

Referencias

De Vito, S., Massera, E., Piga, M., Martinotto, L., & Di Francia, G. (2008). On field calibration of an electronic nose for benzene estimation in an urban pollution monitoring scenario. *Sensors and Actuators B: Chemical*, 129(2), 750–757.

De Vito, S. (2008). Air Quality [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C59K5F>

Plotly Technologies Inc. (2026). Dash Documentation. <https://dash.plotly.com>